

High Garden coffee

Daniel Camilo Bernal Ternera

Prueba Técnica NTT Data

Julián Plazas
Lead Engineer, NTT Data

NTT Data

Bogotá (Colombia)

2026

1. Problemática.

i. Descripción y contexto del problema:

La empresa "High Garden Coffee" quiere desarrollar una herramienta de innovación con inteligencia artificial para poder tener una ventaja competitiva. Esta empresa posee un registro histórico de consumo de café en tazas que abarca desde el año 1990 hasta el 2020, sin embargo, presenta problemas importantes de calidad, como diferentes países donde los datos se mantenían exactos durante años, lo cual no representa un consumo humano real, sino datos artificiales, estimaciones o errores en la recolección que serán ruido dentro del modelo. Estos vacíos de información presentaron un nuevo problema sobre la falta de "memoria" histórica confiable en muchos de los países registrados, impidiendo una proyección matemática por parte de una herramienta de innovación con inteligencia artificial. Por otro lado, así se tuviera la información requerida, también es igual de importante descubrir cómo traducir dichas proyecciones en una ventaja competitiva real y accionable para la toma de decisiones, puesto que un dato numérico por sí solo, no tiene gran impacto si no viene acompañado de un análisis comercial experto.

Ante la nula variedad de información disponible, la carencia de continuidad temporal, patrones que señalan la presencia de datos artificiales y estimaciones que no reflejan fielmente la realidad del mercado, se decidió optar por la siguiente propuesta.

ii. Objetivos:

Objetivo principal: Desarrollar una plataforma que combine un modelo predictivo con un agente de inteligencia artificial que pueda actuar como consultor estratégico, transformando datos históricos de consumo en insights valiosos para la expansión en mercados emergentes.

Objetivos secundarios:

- Implementar un pipeline de limpieza y enriquecer los datos existentes para entrenar un modelo LightGBM.

- Diseñar y desplegar una infraestructura cloud utilizando AWS y Docker para la integración de un modelo de Gemini.
- Documentar y evaluar los resultados obtenidos para poder establecer una base técnica para futuros desarrollos.

2. Propuesta de Solución.

Para desarrollar una demo que pueda resolver los problemas antes descritos, se optó por construir un modelo que pueda identificar tendencias de consumo y detectar mercados emergentes, transformando de esta manera, la limitación de datos en una ventaja competitiva, para que el usuario pueda enfocar la herramienta en señalar qué países pueden presentar un crecimiento que represente oportunidades de expansión para su negocio.


Además, para maximizar el valor de estas predicciones, se implementó un agente inteligente que actúa como un analista de mercado que pueda utilizar diferentes herramientas según la pregunta del usuario y de la información conocida de los países. Por ejemplo, ante datos desactualizados, el agente es capaz de buscar un "país proxy" (es decir, con estructuras de mercado similares) para ofrecer una estimación según patrones de comportamiento aprendidos de países con datos completos, aplicando un concepto similar al transfer learning.

Por último, se decidió desarrollar esta herramienta en AWS para que pueda ser usada de manera intuitiva a través de un portal web, incrementando su accesibilidad y facilidad de uso. Así mismo, al utilizar una arquitectura orientada a los microservicios se permite la mejora continua modularmente, para mejorar las capacidades del agente o de la interfaz individualmente.

i. Análisis de datos y modelo predictivo:

El proceso de preparación y modelado tuvo su inicio con la exploración y limpieza del dataset original para garantizar que las predicciones estuvieran fundamentadas en comportamientos de consumo reales y no en ruido estadístico, de esta forma, se encontraron inconsistencias en los tipos del café y se estandarizaron categorías como “Arabica/Robusta” y “Robusta/Arabica”.

Así mismo, se tomó la decisión de excluir países como Guinea Ecuatorial y Nepal, los cuales presentaban registros de consumo nulos a pesar de ser mercados activos, lo cual, es un fallo en la recolección de los datos originales. Siguiendo con la limpieza, se determinó habían datos artificiales y para profundizar en la calidad, se implementó una función de detección de estas secuencias constantes que eliminó los valores repetidos durante años, asegurando que el modelo solo tuviera datos "vivos" que reflejaran la dinámica real del mercado.



Esta figura representa el antes y el después de los datos de consumo en Costa Rica.

Con los datos disponibles y debido a su irregularidad y la falta de continuidad, se tomó la decisión estratégica de centrar el objetivo del negocio en predecir la variación porcentual del consumo y detectar mercados emergentes. De lo contrario, de haber predicho un valor en bruto, los valores de consumo excesivos de Brasil y otros, arrastrarán los valores de países con un consumo pequeño, terminando así con un modelo que no podría superar a uno que asume que el consumo anterior será el mismo que el de ahora (un modelo Naive). Por esta razón, si solo se tiene en cuenta la proporción de cambio, no es relevante si un país de consumo pequeño aumenta en un dos por ciento y otro de consumo gigante también lo hace, aunque represente una diferencia de miles de tazas.


Por otro lado, se determinó que se debería utilizar un modelo que pudiera procesar datos nulos, ya que hay países que quedaron con vacíos en sus récords de consumo. De igual manera, al diseñar este modelo como una herramienta para un agente inteligente, se requiere que la predicción sea rápida y precisa, por estas razones se empleó el modelo LightGBM.

Ahora bien, para darle al modelo un contexto macroeconómico de oferta y demanda que el dataset original no poseía, se integraron series temporales que contenían precios globales del café Arabica y Robusta. Con esta información se permitió al sistema una alternativa de entender una dinámica de

oferta y demanda, representada en cómo las fluctuaciones del precio internacional impactan directamente en las tasas de consumo de cada país.


Ya con los datos enriquecidos y limpiados, se utilizó una segmentación para que el modelo solo fuera entrenado con los países más completos, para esto se aplicó una metodología de separación por cantidad de datos dividiendo los países en "Anclas" y "Objetivos". Los países ancla, que contaban con más de la mitad de los datos “vivos”, permitiéndole al modelo aprender curvas de saturación y la dinámica real del mercado. Este enfoque permitió aplicar una técnica similar al Transfer Learning, donde el conocimiento extraído de mercados con datos “vivos” (los países ancla) se utiliza para poder inferir tendencias en países con información limitada (los países objetivo), resolviendo de esta manera el problema de la falta de datos.

Ahora bien, para poder darle "memoria" al modelo LightGBM y una noción del comportamiento del mercado, se crearon “Lags” de hasta tres años para capturar el movimiento de los contratos comerciales a largo plazo. Además, se implementaron medias móviles y desviaciones estándar para suavizar picos desproporcionados y representar la volatilidad del mercado y al categorizar los países por su tamaño de mercado (Gigante, Grande, Mediano, Pequeño) se logró evitar que casos atípicos, como el volumen masivo de Brasil, sesgen las predicciones de naciones más pequeñas, resultando en que el modelo pudiera ajustar sus pesos de manera diferenciada según la escala de cada economía.



Esta figura representa que el modelo está libre de sesgos y sus errores no son grandes.

Finalmente, la evaluación del modelo demostró su capacidad para superar la inercia del mercado (modelo Naive), logrando un MAPE (Error Absoluto Medio Porcentual) del 2.45% en las fases de validación más estables, lo que demuestra que es un modelo excelente. Además como se puede ver en la gráfica anterior, los mercados con consumos pequeño y mediano, tienen un error casi de cero, los mercados medianos no presentan un patrón detectable, lo que quiere decir que a mayor consumo no hay un incremento del error y por último, el mercado gigante de Brasil no significa un error grande dentro del modelo, si se evalúa según su tamaño de mercado. Un consumo de 1,320 millones con desvío de 36 millones realmente equivale a un error de apenas 2.7%. Esto señala que la variación de consumo como variable objetivo fue la mejor decisión para mantener la precisión en diferentes escalas.



Esta figura representa la comparación de las métricas MAPE y RMSE del modelo LGBM con el Naive en los diferentes folds temporales del entrenamiento.

Durante el entrenamiento del modelo, hubo un aumento del error en el periodo cercano a la pandemia, donde fue el único caso donde el modelo no pudo superar al Naive, se optó por no cambiar los datos de ese periodo y tratarlo como un evento externo imprevisto que alteró el comportamiento histórico, mostrando que el sistema puede evolucionar y adaptarse a nuevas realidades si se tienen los datos actualizados.

ii. Inteligencia Artificial Generativa:

En cuanto a la implementación del agente, se empleó una arquitectura de orquestación dinámica utilizando el framework LangChain y el modelo ChatGoogleGenerativeAI de Gemini. Asimismo, para garantizar que la herramienta actúe como un consultor de negocios determinista y no de forma conversacional, se configuró el modelo con una temperatura baja, priorizando la precisión analítica y determinista.

Esta solución se basa en un sistema "Router Dinámico" para que pueda evaluar las preguntas del usuario bajo unas estrictas reglas de negocio, estas consisten en filtrar si el usuario busca predecir precios, donde el agente aclara que se enfoca en tendencias de consumo. Segundo, validar la vigencia de los datos, para poder saber si se trata de un país con históricos vacíos. Y tercero, determinar si la consulta requiere de una simulación de corto plazo o un escenario de estrés futuro, además de analizar si tiene todos los datos para hacer una predicción o si necesita solicitarle al usuario que los proporcione.

En esta implementación se tomaron las decisiones técnicas más críticas, dada la restricción de la capa gratuita de la API de Gemini, fue importante el desarrollo de un controlador de pausas personalizado denominado `RateLimitCallbackHandler`. Tiene la función de interceptar cada petición antes de ser enviada al modelo de lenguaje, forzando una espera controlada que previene el bloqueo por exceso de solicitudes. Esta solución no solo permite la estabilidad del prototipo en un entorno de demo, sino que demuestra una capacidad de ingeniería para adaptar soluciones avanzadas a limitaciones de infraestructura reales, asegurando que la experiencia del usuario final no se vea interrumpida por errores de cuota.

Con lo anterior en cuenta, el ecosistema de herramientas (tools) fue diseñado específicamente para conectar al LLM con el modelo `LightGBM` y la base de datos procesada para realizar la predicción. Por ejemplo, la herramienta `simular_impacto_precio` permite al agente llamar al modelo de machine learning de forma autorregresiva, inyectando variables externas dadas por el usuario como el precio global para proyectar el consumo futuro.


Así mismo, para solucionar el problema de los datos faltantes en los países, se implementó `buscar_country_proxy`, la cual es una función estratégica que permite al agente identificar países con estructuras de mercado similares (mismo tipo de café y tamaño de mercado) para ofrecer estimaciones, el agente le da al usuario los países con datos completos mas parecidos para hacer la predicción.

Y para poder gestionar la integridad de la información y evitar alucinaciones, el agente utiliza la herramienta `solicitar_parametro_exogeno`, la cual actúa como un mecanismo de control que se activa cuando una consulta de predicción se puede hacer pero faltan datos necesarios del contexto, como el valor del precio global esperado. Por último, se integró conceptualmente la herramienta `simulacion_what_if_global` para proyecciones para muchos años en el futuro. Aunque su lógica general está construida, su uso se mantiene bajo un enfoque de desarrollo modular, debido a que la complejidad de estas simulaciones requieren de recursos computacionales superiores a los de la capa gratuita actual.

En su totalidad, el agente puede ser una interfaz experta que no sólo entrega resultados numéricos, sino que comunica los razonamientos internos y las herramientas utilizadas en cada paso. Por otro lado, al cargar el modelo `LightGBM` en su formato nativo (`booster.txt`) dentro del backend del agente, se logró una integración más estable y rápida, evitando las incompatibilidades de otras librerías, asegurando

que las reglas y pesos aprendidos durante el entrenamiento se apliquen de forma consistente en cada inferencia del Agente.

iii. Despliegue web:



Esta figura representa la arquitectura completa de la herramienta.

Como se mencionó, la arquitectura de este proyecto se diseñó bajo un enfoque de microservicios desacoplados desplegados en AWS, utilizando dos instancias EC2 independientes para poder separar la capa de presentación de la lógica de negocio. En esta separación se pudo hacer que el procesamiento pesado del modelo de Machine Learning y las llamadas al LLM no afecten la disponibilidad de la interfaz de usuario. Además, ambas capas están completamente contenerizadas usando Docker, por medio de imágenes basadas en `python:3.10-slim` para optimizar el peso y la velocidad de despliegue,

para que de esta manera todas las dependencias, como libgomp1 (necesaria para la ejecución nativa de LightGBM), estén presentes sin conflictos de entorno.

Entrando en detalle en la Instancia de Backend (siendo la capa de lógica) esta funciona como la parte inteligente del sistema, pues utiliza el framework FastAPI para exponer un conjunto de endpoints RESTful en el puerto 8000. En esta instancia está el modelo predictivo en formato nativo “modelo_lgbm_cafe_booster.txt” y el dataset procesado “estado_actual_paises.csv”, lo que permite realizar las predicciones rápidas y estables sin depender de wrappers externos. Ahora bien, por razones de seguridad, esta instancia está configurada mediante AWS Inbound Rules para aceptar tráfico exclusivamente proveniente de la IP privada de la instancia de Frontend, protegiendo así el acceso directo a la lógica del agente y los datos sensibles.

Por otro lado, la Instancia del Frontend (siendo la capa de Presentación) también está construida sobre FastAPI, pero teniendo como propósito principal la gestión de la interfaz de usuario mediante plantillas Jinja2 y el servicio de archivos estáticos (CSS/JS). A diferencia de la instancia de la lógica, esta expone el puerto 8000 al tráfico público, permitiendo el acceso de los usuarios finales a la aplicación web. Su comunicación con el backend se realiza de forma interna a través de una variable de entorno que tiene la IP privada de la instancia de lógica, permitiendo que la información viaje de forma segura y eficiente dentro de AWS.

Siguiendo este orden de ideas, el flujo de información entre ambas capas se gestiona mediante peticiones asíncronas y endpoints específicos que dividen el tráfico según lo necesario, por ejemplo, en la gestión de datos, al cargar la aplicación, el frontend realiza una petición GET /paises para llenar un carrusel que se ubicará en la parte superior del portal web. Pero para la visualización de datos, se utilizan los endpoints /api/dashboard y /api/csv_data, los cuales extraen del backend un procesamiento de pandas para poder graficar de manera dinámica en la página. Ahora bien, en la interacción del agente, cuando un usuario envía una consulta a través del formulario del chat, la información viaja mediante un método POST /ask desde el frontend, el cual hace de puente hacia el endpoint /chat del backend. Y es en este punto que el agente procesa el input utilizando LangChain y Gemini, y devuelve una respuesta estructurada que incluye tanto la respuesta final como los pasos lógicos (con las tools usadas) para que se puedan mostrar en la interfaz web.

Esta arquitectura, a pesar de las limitaciones actuales de los recursos de capa gratuita, hace posible que el sistema mantenga una alta disponibilidad y una estructura escalable. Y al estar cada componente en su propio contenedor Docker, la solución está lista para pasar a servicios más robustos, permitiendo que este prototipo evolucione hacia una herramienta de producción empresarial de gran escala.

3. Resultados y discusión.

Esta solución demuestra un potencial muy grande en este momento para poder transformarse en una opción empresarial real. Se es muy consciente de las limitaciones actuales del agente y sus funciones, pero dentro de este mismo entendimiento también se encuentra el valor generado por esta herramienta y su desarrollo.

Esta solución fue creada siguiendo la metodología Scrum, con tres sprints equivalentes cada uno a una jornada de trabajo (análisis y creación del modelo, implementación en la nube y implementación del agente) Como se propone, se puede llegar a soluciones que maximicen el retorno de inversión.

Actualmente, el costo principal no es financiero, sino de tiempo de desarrollo y deuda técnica al construir cada componente desde cero.

i. El empleo de Gemini desde cero

En cuanto a la decisión de utilizar Gemini y la implementación del agente desde cero, esta se fundamentó en la demostración una capacidad avanzada para orquestar arquitecturas de IA complejas, pudiendo desarrollar más allá de soluciones que estén preconstruidas. A la hora de integrar Gemini con frameworks como LangChain, se pudo construir un sistema de herramientas personalizadas (como lo son `simular_impacto_precio` y `buscar_country_proxy`) que tienen la capacidad de interactuar directamente con la lógica de negocio y el modelo LightGBM para hacer predicciones.

Por otro lado, siendo muy consciente de que para poder superar las limitaciones de cuota de la API gratuita, se empleó un desarrollo extra en un controlador de límites de tasa (`RateLimitCallbackHandler`) que gestiona las pausas entre peticiones. Finalmente demuestra que existe la capacidad de llegar a una ingeniería proactiva que puede estabilizar soluciones rápidas bajo restricciones de recursos. A pesar de significar en un tiempo extra invertido, esta arquitectura permite

un control total sobre el flujo de pensamiento del agente, garantizando un análisis determinista y justificado en cada paso de la inferencia.

ii. Alcance del agente actual

A la hora de medir los resultados obtenidos y el potencial de mejora de la solución, es muy importante reconocer que el sistema actual tiene varias limitaciones y actúa como un prototipo de alta fidelidad que genera valor estratégico inmediato, aunque posea oportunidades claras de mejora.

Actualmente, el agente se especializa en identificar tendencias de consumo y mercados emergentes, pero tiene la limitación de no predecir precios directamente, enfocándose en la variación porcentual del consumo para mantener la precisión del modelo. Por otro lado, las restricciones de la capa gratuita impiden realizar múltiples llamadas a herramientas en una sola sesión debido al agotamiento de la cuota, lo que restringe la profundidad del análisis multietapa. Sin embargo, la estructura es escalable y permite, que en próximos desarrollos, se integren fuentes de datos adicionales como la densidad demográfica o indicadores macroeconómicos más específicos para poder llegar a tener un analista experto del mercado.

iii. Futuro empresarial

Finalmente, en cuanto al futuro de esta demo y una potencial optimización mediante Copilot, la transición hacia plataformas como Copilot Studio termina en una oportunidad estratégica para reducir drásticamente los tiempos de desarrollo y los costos operativos. Puesto que al implementar esta lógica en Copilot se puede ahorrar aproximadamente un sprint completo de trabajo porque se evitaría la configuración de infraestructura y orquestación desde cero (como lo son la creación del backend, manejo de hilos y prompts básicos)

De esta manera, la experiencia adquirida en el desarrollo del "Router Dinámico" actual es directamente transferible a Copilot mediante la configuración de "Temas" (Topics), los cuales actuarían como los nodos de decisión que en este momento se gestionan manualmente en el código del agente. Esta migración no solo optimizaría el uso de recursos computacionales en AWS, sino que facilita en gran

medida la integración de conectores nativos para el manejo de datos, permitiendo que la solución escale a nivel empresarial con una gestión de diálogos más robusta y un menor mantenimiento técnico.

4. Conclusión.

Finalmente se ha podido demostrar que es posible transformar un conjunto de datos complejo y con ruidos significativos en una herramienta estratégica de alto valor, pues se logró identificar y solucionar problemas críticos en la información original, permitiendo el entrenamiento de un modelo de Machine Learning (LightGBM) con un desempeño excelente, evidenciado por un MAPE del 2.45% en su fase de validación. Confirmando que la metodología de segmentación, sumada a una ingeniería de características con variables pasadas y medias móviles, da una base sólida y confiable para la toma de decisiones estratégicas.

En cuanto a la implementación del agente, se demuestra que es posible crear una solución que no solo analice datos, sino que actúe como un consultor capaz de integrar el modelo predictivo con herramientas personalizadas para lograr una ventaja competitiva. En este momento el sistema es capaz de identificar tendencias de consumo emergentes y proporcionar información clave que permite a la empresa anticiparse a las dinámicas del mercado internacional, cumpliendo así con los objetivos básicos de innovación planteados en el reto.

Ahora bien, si se tiene en cuenta que esta herramienta es un prototipo funcional con limitaciones, posee un potencial muy bueno para evolucionar a una plataforma empresarial definitiva. Siguiendo este orden de ideas, la arquitectura actual, diseñada sobre microservicios y contenedores, propone una futura evolución con herramientas de escala corporativa como Microsoft Copilot. Donde podría optimizar recursos, reducir tiempos de implementación y expandir las capacidades del agente hacia un análisis más completo, siendo una solución perfecta para el liderazgo de "High Garden Coffee" en el mercado global del café.